



Universidade do Minho
Departamento de Informática

Redes Neurais Artificiais

ADI³ - LEI @ 2025/2026, 2º sem




- Sistemas conexionistas
- Redes Neurais Artificiais
- Arquiteturas recorrentes






Aprendizagem por Máquinas (Machine Learning)



Source: The map of the machine learning world
Vasily Zubarev (vas3k.com)




Redes Neurais Artificiais



youtube.com/watch?v=aircArumnKk



Evolução Redes Neurais Artificiais



S. McCulloch - W. Pitts



F. Rosenblatt



B. Widrow - M. Hoff



M. Minsky - S. Papert




D. Rumelhart - G. Hinton - R. Williams




V. Vapnik - C. Cortes




G. Hinton - S. Ruslan




- Adjustable Weights
- Weights are not Learned




- Learnable Weights and Threshold




- XOR Problem



- Solution to nonlinearly separable problems
- Big computation, local optima and overfitting



- Limitations of learning prior knowledge
- Kernel function: Human Intervention



- Hierarchical feature Learning

[linkedin.com/pulse/history-neural-networks](https://www.linkedin.com/pulse/history-neural-networks)



Redes Neurais Artificiais

Definição


- Uma **Rede Neuronal Artificial** (RNA) é um sistema computacional de base conexionista para a resolução de problemas.
- Uma RNA é concebida com base num **modelo** simplificado **do sistema nervoso central** dos seres humanos.
- Uma RNA é definida por uma estrutura interligada de unidades computacionais, designadas **neurónios**, com capacidade de **aprendizagem**.





Conceitos e definições

- O neurónio é a unidade computacional básica de composição duma RNA, é identificado pela sua posição na rede e é caracterizado pelo valor do estado;
- O axónio é a via de comunicação entre os neurónios, liga qualquer neurónio e a informação circula em um só sentido;
- As sinapses são o ponto de ligação entre os axónios e os neurónios, cujo valor determina o peso do sinal que entra no neurónio; a variação no tempo caracteriza a aprendizagem da RNA;
- A ativação é representada por um único valor que varia com o tempo;
- A função de transferência determina o valor que é colocado na saída, calculado como uma função do valor de ativação.








Tarefas dos neurónios

- Cálculo do valor de saída (output = O_i), função do valor de ativação, por uma função de transferência (f_T):

$$O_i = f_T (A_i)$$



- Cálculo do valor de ativação (A_j).
- Varia no tempo com o seu próprio valor e o de outras entradas ($w_i ; I$):


$$A_j = \mathcal{F}(A_{j-1}; I_j; \sum w_{i,j} \times O_i)$$

- **Aprendizagem:** regras de modificação dos pesos (w_i).




Organização dos neurónios

- Arquitetura *Feed forward*, multi-camada:
(*Multi-layer Perceptron*)



- Arquitetura Recorrente





Regras de aprendizagem

- O treino de uma RNA corresponde à **aplicação de regras de aprendizagem**, por forma a fazer **variar os pesos das ligações** (sinapses);
- Regras de aprendizagem mais comuns:
 - *Hebbian Learning Rule*
 - *Perceptron Learning Rule*
 - *Widrow-Hoff Learning Rule (Delta Rule)*
 - *Competitive Learning Rule (Winner-takes-it-all Rule)*
 - *Correlation Learning Rule*
 - *Outstar Learning Rule (Grossberg Rule)*





Conclusões






Redes Neurais Artificiais

Definição

- Uma **Rede Neuronal Artificial** (RNA) é um sistema computacional de base conexionista para a resolução de problemas.
- Uma RNA é concebida com base num **modelo** simplificado **do sistema nervoso central** dos seres humanos.
- Uma RNA é definida por uma estrutura interligada de unidades computacionais, designadas **neurónios**, com capacidade de **aprendizagem**.






Redes Neurais Artificiais

Aplicação

- As **Redes Neurais Artificiais** (RNA) apresentam-se especialmente adequadas para o reconhecimento de padrões;
- As **RNA** resolvem problemas percebendo o “comportamento” evidenciado pelos dados;
- Os dados que caracterizam os problemas são definidos por vetores;
- As **RNA** têm mostrado capacidade para resolver uma grande diversidade de problemas:
 - Reconhecimento de imagens;
 - Análise de áudio e vídeo;
 - Previsão/Classificação;
 - Tratamento de texto;
 - Análise de séries temporais;
 -
 - ...








Redes Neurais Artificiais

Feedforward

youtube.com/watch?v=aircAruvnKk






Redes Neurais Artificiais

Feedforward



- Após o treino, quando apresentado um problema, uma RNA expõe a resposta que aprendeu...





Redes Neurais Artificiais *Feedforward*

- ... e assim sucessivamente;






Redes Neurais Artificiais

Feedforward

- A resposta a um novo problema **está condicionada** pela solução do problema anterior?






Redes Neurais Artificiais

Feedforward

- A resposta a um novo problema **está condicionada** pela solução do problema anterior? **NÃO**
- Redes *Feedforward* :
 - não têm qualquer noção de ordem, de sequência ou de tempo;
 - são “amnésicas” no que respeita à resolução de problemas passados;
 - apenas recordam o que aprenderam durante o treino;





Universidade do Minho
Departamento de Informática

Redes Neurais Artificiais


Recurrent Neural Networks

ADI³ - LEI @ 2025/2026, 2º sem



Problemas caracterizados por Sequências (tipicamente, o tempo)


- A partir deste “*frame*”, pretende-se prever o movimento da bola;





Problemas caracterizados por Sequências (tipicamente, o tempo)


- A partir deste “*frame*”, pretende-se prever o movimento da bola:
 - Qual a posição no próximo instante de tempo (“*frame*”)





Problemas caracterizados por Sequências (tipicamente, o tempo)


- A partir deste “*frame*”, pretende-se prever o movimento da bola:
 - Qual a posição no próximo instante de tempo (“*frame*”)
 - Sem outra informação de contexto, a previsão não será mais do que um resultado aleatório!






Problemas caracterizados por Sequências (tipicamente, o tempo)


- A partir deste “*frame*”, pretende-se prever o movimento da bola:
 - No próximo “*frame*”, a bola encontra-se nesta posição;





Problemas caracterizados por Sequências (tipicamente, o tempo)



- A partir deste “*frame*”, pretende-se prever o movimento da bola:
 - No próximo “*frame*”, a bola encontra-se nesta posição;
 - É possível estimar o percurso da bola:





Problemas caracterizados por Sequências (tipicamente, o tempo)



- A partir deste “*frame*”, pretende-se prever o movimento da bola:
 - No próximo “*frame*”, a bola encontra-se nesta posição;
 - É possível estimar o percurso da bola;
 - A partir desta sequência, é possível extrapolar o percurso da bola:





Problemas caracterizados por Sequências (tipicamente, o tempo)



- Esta previsão do percurso da bola é válido?





Problemas caracterizados por Sequências (tipicamente, o tempo)


- Esta previsão do percurso da bola é válido?
- Mas, o que acontece à qualidade da previsão se formos perdendo conhecimento sobre os estados anteriores?





Problemas caracterizados por Sequências (tipicamente, o tempo)



- Esta previsão do percurso da bola é válido?
- Mas, o que acontece à qualidade da previsão se formos perdendo conhecimento sobre os estados anteriores?
 - A melhor previsão será esta?





Problemas caracterizados por Sequências (tipicamente, o tempo)


- Esta previsão do percurso da bola é válido?
- Mas, o que acontece à qualidade da previsão se formos perdendo conhecimento sobre os estados anteriores?
 - A melhor previsão será esta?
 - Ou será esta?





Problemas caracterizados por Sequências (tipicamente, o tempo)


- Esta previsão do percurso da bola é válido?
- Mas, o que acontece à qualidade da previsão se formos perdendo conhecimento sobre os estados anteriores?
 - A melhor previsão será esta?
 - Ou será esta?
 - Ou esta?






Problemas caracterizados por Sequências (tipicamente, o tempo)

- Esta previsão do percurso da bola é válido?
- Mas, o que acontece à qualidade da previsão se formos perdendo conhecimento sobre os estados anteriores?
 - Qual é a melhor previsão, se formos perdendo conhecimento ao longo do desenrolar da sequência?






Problemas caracterizados por Sequências (tipicamente, o tempo)






Organização dos neurónios

- Arquitetura *Feed forward*, multi-camada:
(*Multi-layer Perceptron*)




- Arquitetura Recorrente





Recurrent Neural Networks (RNN)

- *Recurrent Neural Networks* - Redes Neurais Recorrentes (ou Recursivas)
 - Conceito introduzido por Jeffrey L. Elman no início dos anos 90;
(link.springer.com/article/10.1007/BF00114844)
 - *Simple Recurrent Network* (SRN)
- O *input* é caracterizado por 2 partes:
 - Exemplo
 - Percepção anterior
- A decisão que a SRN calculou na iteração anterior influenciará a decisão a tomar na iteração atual;
- Traduz-se num efeito de “memória” na rede;





Recurrent Neural Networks (RNN) **Aplicações**

- Qualquer problema que lide com ocorrências em sequência:
 - Reconhecimento de fala (*Speech Recognition*);
 - Previsão em mercados financeiros;
 - Música e vídeo;





Recurrent Neural Networks (RNN) **Aplicações (e complicações)**

- Qualquer problema que lide com ocorrências em sequência:

- Reconhecimento de fala (*Speech Recognition*);
- Previsão em mercados financeiros;
- Música e vídeo;



- “Simples tão assim ser não pode contratações nas preconceito o com acabar”
([expresso.pt/podcasts/a-ia-e-tu/\(....\)](https://expresso.pt/podcasts/a-ia-e-tu/(....)))



Recurrent Neural Networks (RNN) **Aplicações (e complicações)**


- Qualquer problema que lide com ocorrências em sequência:

- Reconhecimento de fala (*Speech Recognition*);
- Previsão em mercados financeiros;
- Música e vídeo;



- “Simples tão assim ser não pode contratações nas preconceito o com acabar”
([expresso.pt/podcasts/a-ia-e-tu/\(....\)](https://expresso.pt/podcasts/a-ia-e-tu/(....)))

- Tabuada do “7”: quanto é 7 x 8?





Recurrent Neural Networks (RNN) **Aplicações (e complicações)**


- Qualquer problema que lide com ocorrências em sequência:

- Reconhecimento de fala (*Speech Recognition*);
- Previsão em mercados financeiros;
- Música e vídeo;



- “Simples tão assim ser não pode contratações nas preconceito o com acabar”
([expresso.pt/podcasts/a-ia-e-tu/\(....\)](https://expresso.pt/podcasts/a-ia-e-tu/(....)))

- Tabuada do “7”: quanto é 7 x 8?



- Alfabeto: quais as 5 letras a seguir ao “Q”?



Recurrent Neural Networks (RNN)

Aplicações (e complicações)


- Qualquer problema que lide com ocorrências em sequência:

- Reconhecimento de fala (*Speech Recognition*);
- Previsão em mercados financeiros;
- Música e vídeo;



- “Simples tão assim ser não pode contratações nas preconceito o com acabar”
([expresso.pt/podcasts/a-ia-e-tu/\(....\)](http://expresso.pt/podcasts/a-ia-e-tu/(....)))

- Tabuada do “7”: quanto é 7×8 ?




- Alfabeto: quais as 5 letras a seguir ao “Q”?

- Soletre a palavra “ALFABETICAMENTE” da última letra para a primeira;



Recurrent vs Feedforward

- As redes recorrentes distinguem-se das *feedforward* pelo ciclo que traz as decisões anteriores até ao momento atual;
- Esta memória na rede tem uma função: **captar a noção de tempo!**
- A noção de tempo permite capacitar as redes para resolver problemas com características de sequenciação de ocorrências;




James L. McClelland, 2015

web.stanford.edu/group/pdplab/pdphandbook/handbookch8.html



Recurrent vs Feedforward

- As redes *Feedforward* utilizam algoritmos de *BackPropagation* (BP) para estimar os erros que a rede está a produzir nos pesos das camadas anteriores, durante a fase de aprendizagem;




$$f_A(P, E) = \sum P \times E$$

$$f_r(A) = A$$



Recurrent vs Feedforward

- As redes *Feedforward* utilizam algoritmos de *BackPropagation* (BP) para estimar os erros que a rede está a produzir nos pesos das camadas anteriores, durante a fase de aprendizagem;




$$\mathcal{E} = OUT_D - OUT_C$$

$$\mathcal{E}_{\leftarrow} = \mathcal{E} \times P$$



Recurrent vs Feedforward

- As redes *Feedforward* utilizam algoritmos de *BackPropagation* (BP) para estimar os erros que a rede está a produzir nos pesos das camadas anteriores, durante a fase de aprendizagem;




$$\mathcal{E} = OUT_D - OUT_C$$

$$\mathcal{E}_{\leftarrow} = \mathcal{E} \times P$$




Recurrent vs Feedforward

- As redes *Feedforward* utilizam algoritmos de *BackPropagation* (BP) para estimar os erros que a rede está a produzir nos pesos das camadas anteriores, durante a fase de aprendizagem;
- As redes recorrentes usam uma extensão deste conceito, designado *BackPropagation Through Time* (BPTT);
- A propagação dos erros é, assim, feita através dos instantes de tempo durante o qual a aprendizagem decorre;



Recurrent Neural Network




Feed-Forward Neural Network



Recurrent Neural Networks ***Vanishing/Exploding Gradients Problem***

- A dimensão temporal das RNN apresenta-se de modo recursivo ao longo de toda a execução;




$$x^{(n)} = W^n x^{(0)} \quad \begin{array}{l} x^{(i)}, W \in \mathbb{R} \\ i \in [0, n] \end{array}$$

$$W^n x^{(0)} \rightarrow \begin{cases} \infty; & W > 1 \\ 0; & W < 1 \end{cases}$$



Recurrent Neural Networks ***Vanishing/Exploding Gradients Problem***

- A dimensão temporal das RNN apresenta-se de modo recursivo ao longo de toda a execução;
- Os *inputs* não são apresentados “todos ao mesmo tempo”;




$$x^{(n)} = W^n x^{(0)} \quad \begin{array}{l} x^{(i)}, W \in \mathbb{R} \\ i \in [0, n] \end{array}$$

$$W^n x^{(0)} \rightarrow \begin{cases} \infty; & W > 1 \\ 0; & W < 1 \end{cases}$$



Recurrent Neural Networks ***Vanishing/Exploding Gradients Problem***

- A dimensão temporal das RNN apresenta-se de modo recursivo ao longo de toda a execução;
- Os *inputs* não são apresentados “todos ao mesmo tempo”;
- A estimativa do erro num determinado instante de tempo **t** está dependente do erro no instante **t-1**, e assim sucessivamente através de todas as iterações;



$$x^{(n)} = W^n x^{(0)} \quad \begin{array}{l} x^{(i)}, W \in \mathbb{R} \\ i \in [0, n] \end{array}$$


$$W^n x^{(0)} \rightarrow \begin{cases} \infty; & W > 1 \\ 0; & W < 1 \end{cases}$$



Recurrent Neural Networks

Vanishing/Exploding Gradients Problem

- A dimensão temporal das RNN apresenta-se de modo recursivo ao longo de toda a execução;
- Os *inputs* não são apresentados “todos ao mesmo tempo”;
- A estimativa do erro num determinado instante de tempo t está dependente do erro no instante $t-1$, e assim sucessivamente através de todas as iterações;
- *Exploding Gradients*:
 - Quando o algoritmo atribui grande importância aos pesos, pode acontecer uma “explosão” dos seus valores, o que leva a instabilidade na aprendizagem;






Recurrent Neural Networks

Vanishing/Exploding Gradients Problem

- A dimensão temporal das RNN apresenta-se de modo recursivo ao longo de toda a execução;
- Os *inputs* não são apresentados “todos ao mesmo tempo”;
- A estimativa do erro num determinado instante de tempo t está dependente do erro no instante $t-1$, e assim sucessivamente através de todas as iterações;
- *Exploding Gradients*:
 - Quando o algoritmo atribui grande importância aos pesos, pode acontecer uma “explosão” dos seus valores, o que leva a instabilidade na aprendizagem;
- *Vanishing Gradients*:
 - Quando os valores do gradiente são pequenos, a sua propagação tende a perder influência, o que leva à perda de capacidade de aprendizagem (o algoritmo “congela”);






Recurrent Neural Networks

Vanishing/Exploding Gradients Problem

- A dimensão temporal das RNN apresenta-se de modo recursivo ao longo de toda a execução;
- Os *inputs* não são apresentados “todos ao mesmo tempo”;
- A estimativa do erro num determinado instante de tempo t está dependente do erro no instante $t-1$, e assim sucessivamente através de todas as iterações;
- O problema com *Exploding/Vanishing Gradients*:
 - As RNN tendem a preservar o efeito de memória nos instantes de tempo mais recentes;
 - Desta consequência sobressai a característica de *Short Term Memory* (STM);





- *Recurrent Neural Networks* (RNN) funcionam como uma cadeia de redes *Feedforward*;
- RNN aprendem através de algoritmos de *BackPropagation Through Time* (BPTT);
- RNN são redes com capacidade de memorização;
- São especialmente capacitadas para problemas que envolvem sequências;
- Perante sequências longas, torna-se visível o problema do *Vanish/Exploding Gradient*.





Universidade do Minho
Departamento de Informática

Redes Neurais Artificiais

Long Short-Term Memory & Gated Recurrent Units

ADI³ - LEI @ 2025/2026, 2º sem




Redes Neurais Artificiais

Long Short-Term Memory (LSTM)

- *Long Short-Term Memory units.*

(“muitas unidades de memória de curta duração”)


- Introduzidas por Sepp Hochreiter e Juergen Schmidhuber em meados dos anos 90;
- Extensão ao conceito de Redes Neurais Recorrentes (RNN – *Recurrent Neural Nets*);
- Ultrapassar o problema do *Vanishing/Exploding Gradients*;





Redes Neurais Artificiais


Long Short-Term Memory (LSTM)






Redes Neurais Artificiais

Long Short-Term Memory (LSTM)






Redes Neurais Artificiais *Gated Recurrent Units (GRU)*





Redes Neurais Artificiais

Gated Recurrent Units (GRU)





- *Recurrent Neural Networks* (RNN) funcionam como uma cadeia de redes *Feedforward*;
- RNN aprendem através de algoritmos de *BackPropagation Through Time* (BPTT);
- RNN são redes com capacidade de memorização;
- São especialmente capacitadas para problemas que envolvem sequências;
- Perante sequências longas, torna-se visível o problema do *Vanish/Exploding Gradient*;
- Para minimizar estes problemas surgem as LSTM (e as GRU – *Gated Recurrent Units*);






Referências bibliográficas

- Haykin, S., “Neural Networks - A Comprehensive Foundation”, Prentice-Hall, New Jersey, 2nd Edition, 1999.
- Elman, J. L. (1990). Finding structure in time. Cognitive Science, 14:179-211.
- James McClelland (2015), “Explorations in Parallel Distributed Processing: A Handbook of Models, Programs, and Exercises”, “Chapter 7 - The Simple Recurrent Network: A Simple Model that Captures the Structure in Sequences”
<https://web.stanford.edu/group/pdplab/pdphandbook/handbook.pdf>



Referências bibliográficas

- Cortez, P., Neves, J., “Redes Neurais Artificiais”, Unidade de Ensino, Departamento de Informática, Universidade do Minho, 2000;
- Haykin, S., “Neural Networks - A Comprehensive Foundation”, Prentice-Hall, New Jersey, 1999, ISBN 978-0-13-273350-2;
- Bishop, Christopher M., “Neural networks for pattern recognition”, Clarendon Press, 1995, ISBN 978-0-19-853849-3;
- Charu C. Aggarwal, “Neural Networks and Deep Learning”, Springer, 2018, ISBN 978-3-319-94463-0.





Universidade do Minho
Departamento de Informática

Redes Neurais Artificiais

ADI³ - LEI @ 2025/2026, 2º sem