

Este fluxo de trabalho no KNIME foi desenvolvido para realizar uma análise exploratória completa e criar um modelo de previsão para a classificação de espécies de flores Iris (Setosa, Versicolor e Virginica).

## 1. Ingestão e Preparação de Dados

- **Excel Reader:** O ponto de partida onde o dataset «iris» é carregado para o ambiente de trabalho.
- **Table Partitioner:** Os dados são divididos em dois conjuntos: um conjunto de **treino** (para a árvore aprender) e um conjunto de **teste** (para validar se a árvore aprendeu bem).

## 2. Exploração e Análise Estatística (EDA)

Nesta fase, analisamos as características numéricas (comprimento e largura de pétalas e sépalas) através de três vertentes:


- **Tendências Centrais e Dispersão (Nó Statistics):** Calcula métricas como a média e o desvio padrão para entender a variação dos dados.
- **Correlação (Nó Linear Correlation):** Avalia a força da relação entre as diferentes medidas das flores.
- **Visualização Gráfica:**
  - **Histogram:** Para ver a distribuição das frequências.
  - **Scatter Plot:** Para visualizar a relação entre duas variáveis e como elas agrupam as espécies.
  - **Box Plot:** Configurado com a coluna class para analisar a dispersão e identificar *outliers* em cada espécie individualmente.

## 3. Modelação com Árvores de Decisão


- **Decision Tree Learner:** O algoritmo analisa os dados de treino para criar regras lógicas de decisão (ex: se a largura da pétala for inferior a 0.8, é uma Setosa).
- **Decision Tree Predictor:** O modelo gerado é aplicado aos dados de teste (que o algoritmo ainda não conhece) para prever as respetivas espécies.

## 4. Avaliação de Desempenho

- **Scorer:** Este nó compara as previsões feitas pelo modelo com os valores reais das flores.
- **Matriz de Confusão:** Através desta matriz, observamos a eficácia do modelo. No resultado obtido, o modelo demonstrou uma excelente performance, com apenas ligeiras confusões entre as espécies *Versicolor* e *Virginica* (2 instâncias), enquanto classificou perfeitamente todas as *Setosas*.



Histograma de sepal\_length



► 1: Statistics Table ► 2: Nominal Histogram Table ► 3: Occurrences Table

Rows: 4 | Columns: 16

Table Statistics

| <input checked="" type="checkbox"/> | # | RowID   | Column       | Min | Max | Mean  | Std. devia... | Variance | Skewness | Kurtosis | Overall su... | No. r |
|-------------------------------------|---|---------|--------------|-----|-----|-------|---------------|----------|----------|----------|---------------|-------|
| <input type="checkbox"/>            | 1 | sepal_I | sepal_length | 4.3 | 7.9 | 5.843 | 0.828         | 0.686    | 0.315    | -0.552   | 876.5         | 0     |
| <input type="checkbox"/>            | 2 | sepal_v | sepal_width  | 2   | 4.4 | 3.054 | 0.434         | 0.188    | 0.334    | 0.291    | 458.1         | 0     |
| <input type="checkbox"/>            | 3 | petal_I | petal_length | 1   | 6.9 | 3.759 | 1.764         | 3.113    | -0.274   | -1.402   | 563.8         | 0     |
| <input type="checkbox"/>            | 4 | petal_v | petal_width  | 0.1 | 2.5 | 1.199 | 0.763         | 0.582    | -0.105   | -1.34    | 179.8         | 0     |

Box Plot das Medidas das Flores (Iris)



► 1: Correlation measure   ► 2: Correlation matrix   ■ 3: Correlation model   📄 Flow Variables

Rows: 6 | Columns: 5   Table 📄 Statistics 📄 🔍 📄

| <input checked="" type="checkbox"/> | # | RowID | First column name<br><small>(T: String)</small> | Second column name<br><small>(T: String)</small> | Correlation value<br><small>(N: Number (Float))</small> | p value<br><small>(N: Number (Float))</small> | Degrees of freedom<br><small>(N: Number (Integer))</small> |
|-------------------------------------|---|-------|-------------------------------------------------|--------------------------------------------------|---------------------------------------------------------|-----------------------------------------------|------------------------------------------------------------|
| <input type="checkbox"/>            | 1 | Row0  | sepal_length                                    | sepal_width                                      | -0.109                                                  | 0.183                                         | 148                                                        |
| <input type="checkbox"/>            | 2 | Row1  | sepal_length                                    | peta_length                                      | 0.872                                                   | 0                                             | 148                                                        |
| <input type="checkbox"/>            | 3 | Row2  | sepal_length                                    | peta_width                                       | 0.818                                                   | 0                                             | 148                                                        |
| <input type="checkbox"/>            | 4 | Row3  | sepal_width                                     | peta_length                                      | -0.421                                                  | 0                                             | 148                                                        |
| <input type="checkbox"/>            | 5 | Row4  | sepal_width                                     | peta_width                                       | -0.357                                                  | 0                                             | 148                                                        |
| <input type="checkbox"/>            | 6 | Row5  | peta_length                                     | peta_width                                       | 0.963                                                   | 0                                             | 148                                                        |

## Scorer

► 1: Confusion matrix   ► 2: Accuracy statistics   📄 Flow Variables

Rows: 3 | Columns: 3   Table 📄 Statistics 📄 🔍 📄

| <input type="checkbox"/> | # | RowID        | Iris-setosa<br><small>(N: Number (Integer))</small> | Iris-versicolor<br><small>(N: Number (Integer))</small> | Iris-virginica<br><small>(N: Number (Integer))</small> |
|--------------------------|---|--------------|-----------------------------------------------------|---------------------------------------------------------|--------------------------------------------------------|
| <input type="checkbox"/> | 1 | Iris-set: 18 | 0                                                   | 0                                                       | 0                                                      |
| <input type="checkbox"/> | 2 | Iris-ver: 0  | 10                                                  | 2                                                       | 0                                                      |
| <input type="checkbox"/> | 3 | Iris-virg: 0 | 0                                                   | 0                                                       | 15                                                     |

Analise do scorer: 2 vezes que achou que era o virginica mas na verdade era o versicolor

🚩 Confusion Matrix - 3:10 - Scorer   —   □   ✕

File   Hilite

| class \ Pred... | Iris-setosa | Iris-versicolor | Iris-virginica |
|-----------------|-------------|-----------------|----------------|
| ris-setosa      | 18          | 0               | 0              |
| ris-versicolor  | 0           | 10              | 2              |
| ris-virginica   | 0           | 0               | 15             |

|                           |                     |
|---------------------------|---------------------|
| Correct classified: 43    | Wrong classified: 2 |
| Accuracy: 95,556%         | Error: 4,444%       |
| Cohen's kappa (k): 0,932% |                     |

Ao experimentar diferentes parametrizações, observou-se que o critério **Gini Index** com a opção **MDL Pruning** ativa apresentou o melhor equilíbrio. Sem a poda (Pruning), a árvore tornou-se excessivamente complexa, tentando prever cada detalhe dos dados de treino, o que resultou numa menor capacidade de generalização nos dados de teste (conforme visto na Matriz de Confusão, onde as confusões entre *Versicolor* e *Virginica* aumentaram). O aumento do número mínimo de registos por nó simplificou a visualização da árvore, mas reduziu a precisão global, indicando que o modelo estava a ignorar padrões importantes no comprimento das pétalas.