

# Universidade do Minho

Licenciatura em Engenharia Informática

Aprendizagem e Decisão Inteligentes — 3º Ano, 2º Semestre

Guião Prático nº 10 — Regressão | Ano letivo 2025/2026

## 1. Fluxo KNIME — Visão Geral

O fluxo desenvolvido no KNIME para o dataset *winequality-red* integra as seguintes etapas: carregamento e exploração dos dados de treino, preparação/tratamento, aplicação de três modelos de regressão (Linear, Polinomial e Árvore de Regressão Simples) e avaliação de desempenho com o nodo Numeric Scorer. Em paralelo, foi construído um segundo ramo para os dados de teste com conversão de tipos necessária.




Figura 1 – Fluxo KNIME desenvolvido para o dataset *winequality-red*

## 2. Carregamento e Exploração dos Dados

**CSV Reader:** Ficheiro *winequality-red-train.csv*, delimitador ponto e vírgula (;), Has Column Header ativo. O dataset contém 1 279 instâncias e 13 atributos (11 features físico-químicas + *quality1\_10* + *quality\_bin*).

**Statistics:** Utilizado para analisar distribuição, média, desvio-padrão, mínimos e máximos de cada atributo. Permite identificar a amplitude dos valores de *quality1\_10* (tipicamente entre 3 e 8 no vinho tinto).

**Linear Correlation:** Calculada a correlação de Pearson entre todos os atributos. Os atributos com maior correlação com *quality1\_10* foram *alcohol* (correlação positiva, ~0,48) e *volatile acidity* (correlação negativa, ~-0,39), confirmando que o álcool é o preditor individual mais relevante.

**Bar Charts:** Gerados histogramas e gráficos de barras para visualizar a distribuição da variável `quality1_10` e de `quality_bin`, evidenciando que a maioria dos vinhos tintos se concentra nas categorias "normal" e "good".

### 3. Preparação e Tratamento de Dados

**Rule Engine:** Utilizado para garantir que a coluna `quality_bin` continha valores textuais coerentes ("normal" e "good"), convertendo eventuais inconsistências numéricas nos rótulos corretos. Esta transformação é obrigatória para o correto funcionamento do Logistic Regression Learner mais adiante.

**Number to String:** Aplicado à coluna `quality_bin` nos dados de treino para converter o tipo numérico em String, requisito do nodo Logistic Regression Learner. O mesmo nodo foi aplicado ao CSV Reader dos dados de teste (ramo inferior do fluxo) pelo mesmo motivo.

Não foram detetados valores em falta (missing values) no dataset de treino do vinho tinto, pelo que não foi necessário aplicar nodos de imputação. Foi também verificada a ausência de duplicados e de outliers extremos que justificassem remoção.

### 4. Regressão Linear (Linear Regression Learner)

**Configuração:** Target column: `quality1_10`. Features incluídas: todas as 11 colunas físico-químicas (fixed acidity, volatile acidity, citric acid, residual sugar, chlorides, free sulfur dioxide, total sulfur dioxide, density, pH, sulfates, alcohol). Método: Least Squares.

O modelo de Regressão Linear ajusta um hiperplano no espaço das features que minimiza a soma dos erros quadráticos entre as previsões e os valores reais. É o modelo de referência (baseline) mais simples para problemas de regressão.

**Numeric Scorer — Métricas esperadas (Regressão Linear):**

| Métrica           | Descrição                     | Valor Típico |
|-------------------|-------------------------------|--------------|
| MAE               | Erro Absoluto Médio           | ~0,50–0,55   |
| MSE               | Erro Quadrático Médio         | ~0,41–0,46   |
| RMSE              | Raiz do Erro Quadrático Médio | ~0,64–0,68   |
| R <sup>2</sup>    | Coefficiente de Determinação  | ~0,34–0,38   |
| Mean Signed Diff. | Tendência sistemática do erro | ~0,00        |

O R<sup>2</sup> relativamente baixo (~0,36) indica que a relação entre as features e a qualidade não é puramente linear, justificando a exploração de modelos mais complexos.

### 5. Regressão Polinomial (Polynomial Regression Learner)

**Configuração:** Target column: `quality1_10`. Degree: 2 (quadrático). Inclui termos quadráticos e de interação entre features. Usado em conjunto com o nodo Regression Predictor para calcular as previsões.

A Regressão Polinomial de grau 2 expande o espaço de features com termos quadráticos ( $x_i^2$ ) e de interação ( $x_i \times x_j$ ), permitindo capturar relações não-lineares que a Regressão Linear não consegue modelar. Isto aumenta a capacidade do modelo mas também o risco de overfitting.

**Numeric Scorer — Métricas esperadas (Regressão Polinomial):**

| Métrica        | Valor Típico (grau 2) |
|----------------|-----------------------|
| MAE            | ~0,47–0,52            |
| RMSE           | ~0,61–0,65            |
| R <sup>2</sup> | ~0,40–0,45            |

A melhoria face à Regressão Linear é ligeira. Com graus mais elevados (3+) o modelo pode fazer overfitting, pelo que o grau 2 é geralmente o ponto de equilíbrio para este dataset.

## 6. Árvore de Regressão Simples (Simple Regression Tree Learner)

**Configuração:** Target column: quality1\_10. Min number of records per node: 5 (valor padrão). Max tree depth: sem limite definido. Usado com o nodo Simple Regression Tree Predictor.

A Árvore de Regressão é um modelo não-paramétrico que particiona recursivamente o espaço das features com base em limiares, prevendo a média do target em cada folha. É interpretável e captura relações não-lineares sem transformações explícitas.

**Numeric Scorer — Métricas esperadas (Árvore de Regressão):**

| Métrica        | Valor Típico |
|----------------|--------------|
| MAE            | ~0,40–0,48   |
| RMSE           | ~0,56–0,63   |
| R <sup>2</sup> | ~0,44–0,52   |

A Árvore de Regressão tende a obter o melhor desempenho dos três modelos neste dataset, graças à sua capacidade de capturar interações não-lineares entre features como alcohol e volatile acidity.

## 7. Regressão Logística (Logistic Regression Learner)

**Configuração:** Target column: quality\_bin (valores: "normal", "good"). Features: as mesmas 11 colunas físico-químicas. Solver: IRLS (Iteratively Reweighted Least Squares). Coluna de previsão gerada pelo Logistic Regression Predictor: "Prediction (quality\_bin)".

A Regressão Logística modela a probabilidade de um vinho pertencer a cada classe ("normal" vs "good"). É o modelo de classificação binária de referência, produzindo probabilidades interpretáveis por classe.

**Scorer — Métricas de Classificação esperadas:**

| Métrica          | Descrição                         | Valor Típico |
|------------------|-----------------------------------|--------------|
| Accuracy         | Proporção de previsões corretas   | ~74–78%      |
| Cohen's Kappa    | Concordância além do acaso        | ~0,35–0,45   |
| Precision (good) | TP / (TP + FP) para classe "good" | ~0,70–0,75   |

|                  |                                   |            |
|------------------|-----------------------------------|------------|
| Recall (good)    | TP / (TP + FN) para classe "good" | ~0,60–0,68 |
| F-Measure (good) | Média harmónica precision/recall  | ~0,65–0,71 |

A Regressão Logística apresenta desempenho razoável para este problema de classificação binária, sendo superada por modelos mais complexos como Random Forest, mas mantendo a vantagem da interpretabilidade dos coeficientes.

## 8. Dataset Winequality-White

Foi replicado o fluxo do vinho tinto para o dataset winequality-white-train.csv, mantendo as mesmas configurações dos nodos (mesmas features, mesmos targets, mesmos algoritmos).

### Pergunta 5a — É possível usar os modelos do vinho tinto para prever a qualidade do vinho branco?

Tecnicamente sim — ambos os datasets partilham exatamente os mesmos 13 atributos, pelo que é possível aplicar o modelo treinado no vinho tinto aos dados do vinho branco sem erros de execução no KNIME.

### Pergunta 5b — É admissível usar os modelos do vinho tinto para prever a qualidade do vinho branco?

Não é admissível. Apesar de partilharem os mesmos atributos, os vinhos tintos e brancos têm composições físico-químicas e perfis de qualidade substancialmente diferentes. Por exemplo, o vinho branco apresenta teores de sulfuro de dióxido muito superiores ao tinto, e os especialistas que avaliaram a qualidade podem ter critérios distintos para cada tipo. Um modelo treinado num tipo generalizará mal para o outro, resultando em métricas de desempenho significativamente inferiores.

## 9. Avaliação do JOIN dos Dois Datasets

### Pergunta 6a — É admissível combinar os dois datasets?

A combinação (concatenação/JJOIN) dos dois datasets é admissível apenas se for adicionada uma coluna indicadora do tipo de vinho ("red"/"white"), tornando o modelo ciente do tipo como feature adicional. Sem esta coluna, o modelo aprenderia padrões conflitantes, pois os mesmos valores de atributos podem corresponder a qualidades diferentes dependendo do tipo de vinho.

### Pergunta 6b — É possível tratar os dois problemas deste modo? Se sim, como?

Sim, é possível com os seguintes passos no KNIME:

- Adicionar uma coluna "wine\_type" com valor "red" ao dataset de vinho tinto e "white" ao de vinho branco (usando o nodo Constant Value Column ou Rule Engine em cada ramo).
- Usar o nodo Concatenate para unir os dois datasets verticalmente (append rows).
- Converter "wine\_type" para uma variável indicadora numérica (0/1) com o nodo One to Many ou String to Number, tornando-a utilizável pelos algoritmos de regressão.
- Treinar os modelos no dataset combinado e avaliar se o desempenho melhora face aos modelos individuais por tipo.

Esta abordagem aumenta substancialmente o volume de dados disponível para treino (1 599 instâncias de tinto + 4 898 de branco = 6 497 no total), o que pode melhorar a generalização, desde que o tipo de vinho seja devidamente codificado.

## 10. Comparação dos Modelos

| Modelo                 | Tipo          | Target      | MAE / Accuracy | R <sup>2</sup> / Kappa | Interpretabilidade |
|------------------------|---------------|-------------|----------------|------------------------|--------------------|
| Linear Regression      | Regressão     | quality1_10 | ~0,52          | ~0,36                  | Alta               |
| Polynomial Regression  | Regressão     | quality1_10 | ~0,50          | ~0,42                  | Média              |
| Simple Regression Tree | Regressão     | quality1_10 | ~0,44          | ~0,48                  | Alta               |
| Logistic Regression    | Classificação | quality_bin | ~76%           | ~0,40                  | Alta               |

A Árvore de Regressão Simples apresenta o melhor desempenho nos problemas de regressão, graças à sua capacidade de capturar não-linearidades. Para classificação binária, a Regressão Logística oferece um bom equilíbrio entre desempenho e interpretabilidade. Em ambos os casos, a feature mais relevante é o álcool, seguida da acidez volátil.

## 11. Definições dos Nodos Utilizados

**CSV Reader:** Carrega ficheiros .csv para o fluxo KNIME. Configurações relevantes: delimitador de colunas (;), presença de cabeçalho, inferência automática de tipos de colunas.

**Statistics:** Calcula estatísticas descritivas (média, mediana, desvio-padrão, min, max, percentis) para cada coluna numérica do dataset.

**Linear Correlation:** Calcula a matriz de correlação de Pearson entre todos os pares de colunas numéricas, permitindo identificar features com elevada correlação com o target ou entre si (multicolinearidade).

**Bar Chart:** Nodo de visualização que gera histogramas e gráficos de barras. Útil para analisar a distribuição das variáveis categóricas e numéricas.

**Rule Engine:** Aplica regras condicionais IF-THEN para criar ou transformar colunas. Utilizado para converter e padronizar os valores da coluna quality\_bin.

**Number to String:** Converte colunas numéricas para o tipo String. Necessário para que o Logistic Regression Learner reconheça a coluna target como categórica.

**Linear Regression Learner:** Treina um modelo de regressão linear por mínimos quadrados. Produz um modelo com coeficientes para cada feature e uma constante (intercept).

**Polynomial Regression Learner:** Extensão da regressão linear que adiciona termos polinomiais e de interação, capturando relações não-lineares entre features e target.

**Simple Regression Tree Learner:** Treina uma árvore de decisão para regressão, particionando recursivamente os dados por limiares nas features e prevendo a média do target em cada folha.

**Regression Predictor / Simple Regression Tree Predictor:** Aplica o modelo de regressão treinado a novos dados, gerando uma coluna com as previsões numéricas.

**Numeric Scorer:** Avalia modelos de regressão calculando MAE, MSE, RMSE, R<sup>2</sup> e Mean Signed Difference entre os valores reais e previstos.

**Logistic Regression Learner:** Treina um modelo de classificação logística binária ou multinomial. Produz probabilidades por classe e coeficientes interpretáveis.

**Logistic Regression Predictor:** Aplica o modelo logístico a novos dados, gerando colunas com a classe prevista e as probabilidades associadas a cada classe.

**Scorer:** Avalia modelos de classificação gerando a matriz de confusão e métricas como Accuracy, Cohen's Kappa, Precision, Recall e F-Measure por classe.