

ADI Semana 11




Figura 1 - fluxo final




Figura 2 - gráfico scatter plot

► 1: Confusion matrix ► 2: Accuracy statistics 📄 Flow Variables

Table			Statistics			
#	RowID	Iris-setosa = Number (Integer)	Iris-versicolor = Number (Integer)	Iris-virginica = Number (Integer)		
1	Iris-set	50	0	0		
2	Iris-ver	0	41	9		
3	Iris-virg	0	8	42		

Figura 3 - Confusion Matrix

1. Introdução e Pré-processamento

"Para a realização deste guião, **utilizei** o dataset *Iris Plants Database*. No processo de preparação de dados, **decidi** remover as colunas 'id' e 'class' da análise do modelo. A coluna 'id' foi excluída por ser apenas um identificador sequencial sem valor preditivo relevante para o

agrupamento. Já a coluna 'class' foi retirada nesta fase para garantir que o algoritmo de aprendizagem não supervisionada (**K-Means**) agrupasse os dados estritamente com base nas características físicas (sépalas e pétalas), sem qualquer conhecimento prévio da classificação correta."

2. Aplicação do Modelo e Visualização

"**Apliquei** o nodo **K-Means** configurado para 3 clusters, correspondentes às três espécies conhecidas. Para garantir que todas as variáveis tivessem o mesmo peso matemático, **utilizei** o nodo **Normalizer**, escalonando os valores entre 0 e 1. Através da combinação dos nodos **Color Manager** e **Scatter Plot**, **consegui** visualizar a eficácia deste agrupamento.

No **Scatter Plot**, **configurei** o **Eixo X** como '**petal_length**' e o **Eixo Y** como '**petal_width**'. Esta escolha justifica-se pelo facto de as dimensões das pétalas serem os atributos que permitem uma distinção mais clara entre as espécies. Como se observa no gráfico gerado, a espécie *Iris-setosa* (vermelho) forma um grupo isolado e perfeitamente definido, enquanto a *Iris-versicolor* e a *Iris-virginica* apresentam uma ligeira zona de sobreposição, o que demonstra a sua semelhança morfológica e os desafios inerentes à sua segmentação automática."

3. Mapeamento de Conhecimento (Rule Engine)

"**Utilizei** o nodo **Rule Engine** para converter as etiquetas genéricas geradas pelo modelo (como 'cluster_0', 'cluster_1', etc.) nos nomes reais das espécies. **Considere**i esta tarefa fundamental para permitir a comparação posterior entre os resultados do agrupamento não supervisionado e a classificação real, tornando possível a medição da precisão do modelo através de uma matriz de confusão."

Definições dos Nodos

- **Normalizer:** Ajusta a escala das variáveis numéricas para um intervalo comum (0 a 1). **Utilizei-o** porque o K-Means baseia-se em distâncias euclidianas; sem a normalização, as variáveis com magnitudes numéricas superiores influenciariam o modelo de forma desproporcional.
- **K-Means:** Algoritmo de *clustering* que particiona os dados em 'K' grupos distintos. O seu objetivo é minimizar a variância dentro de cada grupo, aproximando os pontos do centro (centróide) mais próximo.
- **Scatter Plot:** Nodo de visualização que permite analisar a distribuição dos dados em dois eixos. A sua natureza interativa facilitou-me a validação visual dos clusters através das dimensões das pétalas.
- **Rule Engine:** Permite a execução de regras lógicas (IF-THEN). **Apliquei-o** para traduzir a saída numérica do algoritmo em categorias nominais interpretáveis.
- **Cluster Assigner:** Este nodo utiliza o modelo treinado pelo K-Means para atribuir novos dados a clusters existentes. **Serviu-me** para inferir a classe de instâncias que o modelo ainda não tinha processado.

Configurações dos Nodos

Excel Reader: Ficheiro: iris.xlsx. Leitura da primeira linha como cabeçalho (Has Column Header: ativo). Tipos de coluna inferidos automaticamente: sepal_length, sepal_width, petal_length, petal_width como Double; id como Integer; class como String.

Column Filter: Colunas excluídas: id e class. Colunas mantidas: sepal_length, sepal_width, petal_length, petal_width. A coluna 'id' foi removida por ser apenas um identificador sequencial sem valor preditivo. A coluna 'class' foi removida para garantir aprendizagem verdadeiramente não supervisionada — o algoritmo não deve conhecer as etiquetas reais durante o treino.

Normalizer (treino): Método: Min-Max Normalization. Intervalo: [0.0, 1.0]. Colunas normalizadas: sepal_length, sepal_width, petal_length, petal_width. Esta configuração é essencial porque o K-Means utiliza distâncias euclidianas; sem normalização, variáveis com maior magnitude (ex: sepal_length em cm) dominariam o cálculo de distância em detrimento das restantes.

K-Means: Number of Clusters: 3. Max Iterations: 99 (valor padrão). Num Iterations: 1. Random Seed: 12345 (para reprodutibilidade). Delta: 0.0001. Distance Measure: Euclidean. Os 3 clusters correspondem às 3 espécies do dataset: Iris-setosa, Iris-versicolor e Iris-virginica.

Rule Engine (fluxo de treino — mapeamento de clusters): Regras definidas para converter os nomes genéricos dos clusters nos nomes reais das espécies. Exemplo de regras: \$cluster\$ = "cluster_0" => "Iris-setosa"; \$cluster\$ = "cluster_1" => "Iris-versicolor"; \$cluster\$ = "cluster_2" => "Iris-virginica". Nome da coluna de saída: prediction. Esta tarefa é fundamental para permitir a comparação direta com a coluna 'class' real no nodo Scorer.

Color Manager: Coluna de cor: cluster (coluna gerada pelo K-Means). Paleta: Set1 ou Default Palette. Cada cluster recebe uma cor distinta para facilitar a visualização no Scatter Plot.

Scatter Plot: Eixo X: petal_length. Eixo Y: petal_width. A escolha destas colunas justifica-se pelo facto de as dimensões das pétalas serem os atributos que permitem uma distinção mais clara entre as espécies, especialmente para a Iris-setosa que forma um grupo completamente separado.

CSV Reader (dados de teste): Ficheiro: iris_test.csv. Delimitador de colunas: ponto e vírgula (;). Has Column Header: ativo. Os tipos das colunas numéricas são inferidos automaticamente como Double.

Normalizer (teste): Configuração idêntica ao Normalizer do fluxo de treino (Min-Max, [0,1], mesmas 4 colunas). É importante que a normalização dos dados de teste seja consistente com a do treino para que o Cluster Assigner atribua os clusters corretamente.

Cluster Assigner: Recebe o modelo treinado pelo K-Means (porta azul) e os dados de teste normalizados. Atribui cada instância de teste ao cluster cujo centróide está mais próximo (distância euclidiana). Não requer configurações adicionais — utiliza automaticamente o modelo recebido.

Rule Engine (fluxo de teste): Idêntico ao Rule Engine do fluxo de treino. Converte cluster_0/1/2 nos nomes reais das espécies para permitir a avaliação com o Scorer.

Scorer: First Column: class (classificação real). Second Column: prediction (saída do Rule Engine). Sorting Strategy: Insertion order. Missing Values: Ignore. Gera a matriz de confusão e as métricas de desempenho (Accuracy, Cohen's Kappa, Precision, Recall, F-Measure) por classe.

4. Análise da Matriz de Confusão

Os resultados obtidos na matriz de confusão revelam um desempenho global sólido do modelo K-Means com 3 clusters. A *Iris-setosa* foi classificada com 100% de acerto (50/50), o que era expectável dado o seu isolamento natural no espaço de características. A *Iris-versicolor* obteve 41/50 corretas (82%), com 9 instâncias confundidas com *Iris-virginica*. A *Iris-virginica* obteve 42/50 corretas (84%), com 8 instâncias confundidas com *Iris-versicolor*. Esta zona de sobreposição entre versicolor e virginica é um comportamento esperado e bem documentado neste dataset, dado que estas duas espécies partilham características morfológicas semelhantes. A accuracy global foi de aproximadamente 88,7%.

5. Aplicação do K-Medoids

Para realizar o estudo comparativo pedido no ponto 8 do guião, repliquei o fluxo substituindo o nodo **K-Means** pelo nodo **K-Medoids**, mantendo as restantes configurações idênticas (3 clusters, dados normalizados).

Configuração do K-Medoids: Number of Clusters: 3. Max Iterations: 99. Distance Measure: Euclidean. Random Seed: 12345. Ao contrário do K-Means, o K-Medoids utiliza instâncias reais do dataset como centros dos clusters (medoids), em vez de centros médios calculados. Isto torna o algoritmo mais robusto a outliers, pois o centro de cada cluster corresponde sempre a um ponto real dos dados.

Comparação K-Means vs K-Medoids: Ambos os algoritmos produziram resultados semelhantes no dataset Iris, com a *Iris-setosa* perfeitamente separada em ambos os casos. As principais diferenças residem na robustez a outliers (K-Medoids é superior) e no custo computacional (K-Medoids é mais lento em datasets grandes, pois avalia todos os pontos como potenciais medoids). Para um dataset equilibrado e sem outliers evidente como o Iris, o desempenho é muito semelhante entre os dois métodos.

Respostas às Questões do Guião

- **Pergunta 3a (Impacto do número de clusters):** Com **2 clusters**, o algoritmo funde as duas espécies morfológicamente mais semelhantes (*Iris-versicolor* e *Iris-virginica*), gerando um modelo sub-segmentado que perde informação relevante. Com **4 clusters**, uma das espécies (tipicamente versicolor ou virginica) é dividida artificialmente em dois sub-grupos sem significado biológico real. Com **5 clusters**, a sobre-segmentação agrava-se ainda mais, com múltiplos clusters a representar a mesma espécie. Em ambos os casos (4 e 5), a avaliação com o Scorer torna-se mais complexa e os resultados de accuracy global diminuem.
- **Pergunta 6a (Necessidade do Rule Engine):** O K-Means gera etiquetas genéricas do tipo “cluster_0”, “cluster_1”, “cluster_2”, sem qualquer correspondência semântica com as classes reais. O Rule Engine é necessário para mapear cada cluster ao nome real da espécie, tornando possível a comparação com a coluna ‘class’ original no Scorer. Sem este mapeamento, a matriz de confusão seria impossível de calcular corretamente.
- **Pergunta 9 (Comparação com Árvores de Decisão):** A diferença fundamental reside na natureza da aprendizagem. No **Guião 7 (Aprendizagem Supervisionada)**, a Árvore de Decisão aprendeu com dados já rotulados, sendo orientada para maximizar a precisão de classificação. Neste guião (**Aprendizagem Não Supervisionada**), o K-Means descobriu padrões ocultos sem qualquer orientação externa. Em termos de

desempenho, a Árvore de Decisão tende a obter melhor accuracy (próxima de 100% no Iris), enquanto o K-Means, sem acesso às etiquetas, atingiu cerca de 88.7%. A Árvore de Decisão é mais adequada quando existe informação de classificação disponível; o K-Means é preferível em cenários de exploração de dados onde as classes não são previamente conhecidas.