

1. Preparação e Pré-processamento de Dados

O objetivo desta etapa foi preparar o *dataset* `flights_delay.csv` para modelagem preditiva, garantindo a integridade dos dados e a ausência de *bias* (enviesamento).

- Limpeza e Filtragem:** Através do nó *Column Filter*, foram excluídas colunas que não contribuem para o objetivo do modelo, com destaque para a remoção de colunas que causavam *Data Leakage* (ex: `ArrDelay`, `ActualElapsedTime`, `TaxiIn`, `CarrierDelay`, etc.). A inclusão destas variáveis resultava num modelo que "batoteava", prevendo o atraso com base em dados que já confirmam a sua ocorrência.
- Tratamento de Valores em Falta:** Utilizou-se o nó *Missing Value* para tratar registros incompletos, sendo configurada a remoção de linhas (*Remove Row*) quando a coluna *target* (`delayed`) não possuía valor definido, assegurando que o modelo é treinado apenas com instâncias de classe conhecida.
- Transformação de Dados:** O nó *One to Many* foi aplicado para converter variáveis categóricas (ex: `UniqueCarrier`, `Origin`, `Dest`) em colunas numéricas (binárias), permitindo que o algoritmo de *Decision Tree* consiga interpretar as características dos voos. Adicionalmente, o nó *Normalizer* foi aplicado para normalizar as variáveis numéricas, garantindo que colunas com escalas distintas não influenciem desproporcionalmente o modelo.

2. Estratégia de Validação e Modelagem

Para a modelagem, utilizou-se a técnica de aprendizagem supervisionada *Decision Tree*. A estratégia de validação adotada foi o *Hold-out Validation* (partição 80/20), utilizando o nó *Table Partitioner* com um *seed* fixo, garantindo a reprodutibilidade dos resultados.

3. Análise de Desempenho

Após a execução do modelo, a performance foi avaliada através da Matriz de Confusão e métricas estatísticas:

[Inserir aqui o screenshot da tua Matriz de Confusão]

Tabela de Resultados (Matriz de Confusão):

Rows: 2 | Columns: 2


Table Statistics

	#	RowID	NO Number (Integer)	YES Number (Integer)
☐	1	NO	537	91
☐	2	YES	94	77


- Análise:** O modelo obteve uma acurácia global de aproximadamente **76,8%**.
- Interpretação:** É notável que o modelo apresenta uma performance sólida a identificar voos sem atrasos (537 Verdadeiros Negativos). Contudo, a capacidade de prever voos com atraso (classe YES) ainda apresenta desafios, com 94 Falsos Negativos (voos que atrasaram mas o modelo previu que não).

Este comportamento é frequente quando existe um desequilíbrio de classes no dataset original, onde os casos de "NO" são mais frequentes que os de "YES".

Nota: No primeiro fluxo que fiz dava 100%, o que não faz sentido e isso vinha de data leakage.



3. Implementação de Regressão Logística e Cross-Validation



Para complementar a análise iniciada com a Árvore de Decisão, procedeu-se à implementação de um modelo de **Regressão Logística**. O objetivo foi comparar a performance de um modelo de natureza estatística com o modelo de base estruturada (árvore) previamente desenvolvido.

- **Estratégia de Validação:** Diferente da abordagem inicial, foi aplicada uma estratégia de **Cross-Validation (10-fold)**, utilizando os nós X-Partitioner e X-Aggregator. Esta abordagem permitiu que o modelo fosse treinado e validado em 10 subconjuntos distintos do dataset, assegurando que os resultados de desempenho obtidos não dependem de uma única partição aleatória dos dados, conferindo maior robustez estatística à avaliação.
- **Ajustes do Modelo:** Devido à natureza do dataset e à transformação *One to Many* aplicada (que aumenta a dimensionalidade), o modelo de Regressão Logística apresentou sensibilidade matemática. Para garantir a estabilidade do processo de otimização, foi configurada a **regularização "Gaussian" (L2)** no nó *Logistic Regression Learner*. Esta técnica permitiu contornar a singularidade da matriz de informação (decorrente de variáveis altamente correlacionadas), garantindo a convergência do modelo.
- **Resultados:** Apesar dos avisos técnicos de convergência (comuns em modelos de regressão com elevada dimensionalidade categórica), o modelo obteve sucesso na classificação, permitindo a extração da Matriz de Confusão e das métricas de performance detalhadas abaixo.

► 1: Confusion matrix

► 2: Accuracy statistics

📄 Flow Variables

Rows: 2 | Columns: 2

Table

Statistics

☐	#	RowID	YES is: Number (Integer)	NO is: Number (Integer)
☐	1	YES	21	75
☐	2	NO	71	233

Tabela Comparativa de Performance:

Name	Type	# Missing valu...	# Unique values	Minimum	Maximum	25% Quantile	50% Quantile (...)	75% Quantile	Mean	Mean Absolut...	Standard Devi...	Sum	10 most comm...
TruePositives	Number (Integer)	1	2	21	233	21	127	233	127	106	149.907	254	21 (1; 50.0%), 23...
FalsePositives	Number (Integer)	1	2	71	75	71	73	75	73	2	2.828	146	71 (1; 50.0%), 75
TrueNegatives	Number (Integer)	1	2	21	233	21	127	233	127	106	149.907	254	21 (1; 50.0%), 23...
FalseNegatives	Number (Integer)	1	2	71	75	71	73	75	73	2	2.828	146	71 (1; 50.0%), 75
Recall	Number (Float)	1	2	0.219	0.766	0.219	0.493	0.766	0.493	0.274	0.387	0.985	0.219 (1; 50.0%),
Precision	Number (Float)	1	2	0.228	0.756	0.228	0.492	0.756	0.492	0.264	0.374	0.985	0.228 (1; 50.0%),
Sensitivity	Number (Float)	1	2	0.219	0.766	0.219	0.493	0.766	0.493	0.274	0.387	0.985	0.219 (1; 50.0%),
Specificity	Number (Float)	1	2	0.219	0.766	0.219	0.493	0.766	0.493	0.274	0.387	0.985	0.219 (1; 50.0%),
F-measure	Number (Float)	1	2	0.223	0.761	0.223	0.492	0.761	0.492	0.269	0.38	0.985	0.223 (1; 50.0%),
Accuracy	Number (Float)	2	1	0.635	0.635	0.635	0.635	0.635	0.635	0	⊖	0.635	0.635 (1; 100.0%),
Cohen's kappa	Number (Float)	2	1	-0.015	-0.015	-0.015	-0.015	-0.015	-0.015	0	⊖	-0.015	-0.015 (1; 100.0%),

Figura 1 - com a logistic

Rows: 11 | Columns: 14

Name	Type	# Missing valu...	# Unique values	Minimum	Maximum	25% Quantile	50% Quantile (...)	75% Quantile	Mean	Mean Absolut...	Standard Devi...	Sum	10 most comm...
TruePositives	Number (Integer)	1	2	77	537	77	307	537	307	230	325.269	614	77 (1; 50.0%), 53...
FalsePositives	Number (Integer)	1	2	91	94	91	92.5	94	92.5	1.5	2.121	185	91 (1; 50.0%), 94
TrueNegatives	Number (Integer)	1	2	77	537	77	307	537	307	230	325.269	614	77 (1; 50.0%), 53...
FalseNegatives	Number (Integer)	1	2	91	94	91	92.5	94	92.5	1.5	2.121	185	91 (1; 50.0%), 94
Recall	Number (Float)	1	2	0.45	0.855	0.45	0.653	0.855	0.653	0.202	0.286	1.305	0.45 (1; 50.0%), 0
Precision	Number (Float)	1	2	0.458	0.851	0.458	0.655	0.851	0.655	0.196	0.278	1.309	0.458 (1; 50.0%),
Sensitivity	Number (Float)	1	2	0.45	0.855	0.45	0.653	0.855	0.653	0.202	0.286	1.305	0.45 (1; 50.0%), 0
Specificity	Number (Float)	1	2	0.45	0.855	0.45	0.653	0.855	0.653	0.202	0.286	1.305	0.45 (1; 50.0%), 0
F-measure	Number (Float)	1	2	0.454	0.853	0.454	0.654	0.853	0.654	0.199	0.282	1.307	0.454 (1; 50.0%),
Accuracy	Number (Float)	2	1	0.768	0.768	0.768	0.768	0.768	0.768	0	⊖	0.768	0.768 (1; 100.0%),
Cohen's kappa	Number (Float)	2	1	0.307	0.307	0.307	0.307	0.307	0.307	0	⊖	0.307	0.307 (1; 100.0%),

Figura 2 - com a decision

Modelo	Estratégia de Validação	Acurácia (Accuracy)	F1-Score
Decision Tree	Hold-out (80/20)	76.8%	0.654
Logistic Regression	Cross-Validation (10-fold)	63.5%	0.492

A Árvore de Decisão demonstrou ser um modelo superior para este dataset, apresentando um F-measure mais equilibrado entre a precisão e a sensibilidade, o que indica uma melhor capacidade de prever atrasos (YES) em comparação com a Regressão Logística.